

Programování 2

3. cvičení, 04-03-2025

Farní oznamy

1. Tento text a kódy ke cvičení najdete v repozitáři cvičení na <https://github.com/PKvasnick/Programovani-2>.


2. **Domácí úkoly:**

- Tento týden jste měli jeden lehký a jeden těžší úkol.
- Jsem globálně spokojený s úrovní řešení.
- Budeme se úkolům dnes věnovat
- Pokud se vám zdá, že jsou pro vás domácí úkoly těžké, napište mi. Je zbytečné, abyste dopláceli na to, že jste v Programování 1 nedostali co jste měli.

Dnešní program:

- Kvíz
- Domácí úkoly
- Blnární vyhledávání

Na zahřátí



"First, solve the problem. Then, write the code." – John Johnson

Neboli **mějte po ruce tužku a papír.**

Toto se týká několika z vás. Pokud máte vážný problém s programováním, měli byste začít právě tímto.

Druhá důležitá ingredience je mít představu o tom, co v Pythonu lze udělat (metody datových typů, kolekce, jejich vlastnosti a použití, základní algoritmy a pod.) a co musíte naprogramovat "ručně".

Co dělá tento kód

Opakování z minulého cvičení.

```
dict(zip(range(1,4), ["Pascal", "Python", "C++", "Javascript"]))
```

zip a **enumerate**: Pokud to je možné, vyhýbáme se iterování přes indexy

```
for i in range(len(seznam)): # NENENE!

for s in seznam:            # OK
for i, s in enumerate(seznam): # OK

for i in range(len(seznam1)): # NE, jen pokud není vyhnutí
    print(seznam1[i] + seznam2[i])

for s1, s2 in zip(seznam1, seznam2): # OK
    print(s1 + s2)
```

- Méně hranatých závorek.
- Ochrana před modifikací dat CO TO ZNAMENÁ?

itertools.pairwise

`zip` a `enumerate` sú len dva príklady iterátorů, kterých existuje celá řada. Jeden další užitečný iterátor:

```
from itertools import pairwise

a = list(range(4))
for p, n in pairwise(a):
    print(p, n)

---
```

```
0 1
1 2
2 3
3 4
```

Pojmenované n-tice

```
from collections import namedtuple
Point = namedtuple("Point", "x y")
point = Point(5, 6)
point.x
Out[5]: 5
point.y
Out[6]: 6
point._asdict()
Out[7]: {'x': 1, 'y': 2}
```

Toto je jedna z možností, jak implementovat kontejner s různorodými daty, která spolu souvisí.

Trošku vadí nepřirozený konstruktor, který ale umožňuje konstruovat `namedtuple` za běhu.

Domácí úkoly

Všimli jste si, co měly domácí úkoly společné?

Minimální a maximální součet

To je docela jednoduchý úkol, přinejmenším proto, že umíme rychle najít slušné řešení: *stačí data setřídít* a vzít k nejmenších a k největších prvků (důkaz?8

```
a = []
while (x := int(input())) != -1:
    a.append(x)

a.sort()

print(sum(a[:k]), sum(a[-k]))
```

Toto je dobré řešení se složitostí $O(n \log n)$. Většinu času můžeme být s takovým řešením spokojení. Co když ale máme obrovské n ? Není to tak nerealistické, takováto vyhledávací úloha je docela významná.

Pozorování:

Pro velké n by bylo výhodné, kdybychom měli jednoprůchodové řešení a nemuseli celou posloupnost načítat do paměti. (Ve vašem domácím úkolu jste posloupnost museli předem načíst, protože až pak se dovíte hodnotu k):

```
# Kdyby byla data rozumně uspořádaná, nejdřív bychom načetli k nebo k a n
k = int(input())

def read_from_console():
    while (x := float(input())) != -1:
        yield x

n = len(5)
```

```

smallest_k = [float("inf")] * k

for x in read_from_console():
    if x > smallest_k[0]:
        continue
    smallest_k[0] = x    # dáme na začátek a probubláme na správné místo
    i = 1
    while smallest_k[i-1] < smallest_k[i] and i < k:
        smallest_k[i-1], smallest_k[i] = smallest_k[i], smallest_k[i-1]

print(sum(smallest_k))

```

Proč tady nemůžeme použít `itertools.pairwise`?

Tady jenom neustále třídíme k-tici, takže složitost bude $O(nk)$. Algoritmus můžeme vylepšit tak, že použijeme lepší způsob vyhledávání pozice pro vložení nové hodnoty a zvolíme datovou strukturu, do které lze levně vkládat nové hodnoty.

Pozorování:

Úplně zbytečně třídíme věci, které nás nezajímají:

- Hodnoty uprostřed
- Hodnoty v k-ticích.

Co s tím?

- jak situace závisí od velikosti k vzhledem k n?
- Příbuzná úloha: k-té největší číslo - budeme řešit podrobněji

Dělicí bod

Všechno nalevo menší, všechno napravo větší. Jednoduché.

Řešení s načtením dat

Hledáme hodnotu, která je maximem hodnot s menším indexem, a minimem hodnot s větším indexem. Všechny levé maxima a pravá minima spočteme rekursivně a pak zjistíme společný index.

```

import sys

def find_partition_point(sequence):
    n = len(sequence)

    if n == 0:
        return -1
    elif n == 1:
        return 0

    max_left = [None] * n
    min_right = [None] * n

    max_left[0] = sequence[0]
    for i in range(1, n):

```

```

max_left[i] = max(max_left[i - 1], sequence[i])

min_right[n - 1] = sequence[n - 1]
for i in range(n - 2, -1, -1):
    min_right[i] = min(min_right[i + 1], sequence[i])

for j in range(1, n - 1):
    if max_left[j - 1] <= sequence[j] <= min_right[j + 1]:
        return j

return -1

sequence = []
for line in sys.stdin:
    num = float(line.strip())
    if num == -1:
        break
    sequence.append(num)

print(find_partition_point(sequence))

```

Průběžné řešení

Udržujeme seznam kandidátů na dělící bod:

- index hodnoty zařadíme do seznamu, pokud je největší dosud viděnou hodnotou. Toto pravidlo zaručuje, že kandidát bude levým maximem.
- ze seznamu odstraníme všechny kandidáty s hodnotou větší než aktuální hodnota. Toto pravidlo zaručuje, že v seznamu máme pravá minima.

Vkládání prvků a vyhledávání v setříděných datech

Klíčové slovo pro tuto úlohu je **binární vyhledávání**, protože v setříděném seznamu lze vyhledávat *fundamentálně* rychleji než v nesetříděném: $\log n$ vs. n , tedy 10 vs. 1000, 20 vs. 1 000 000. Proto používáme abecedně setříděné seznamy věcí, jmenoslovy, slovníky, telefonní seznamy atd.

Vyhledávání v setříděném seznamu

Úloha je najít hodnotu v setříděném seznamu, nebo zjistit, jestli se tam nachází, nebo kolikrát.

Podobně můžeme prohledávat interval na reálné ose, pokud definujeme "rozlišovací schopnost", tedy nejmenší interval, který ještě chceme prohledávat unvitř.

Algoritmus: Půlení intervalu (proto *binární*).

Náročnost: $\log n$.

```

#!/usr/bin/env python3
# Binární vyhledávání v setříděném seznamu

kde = [11, 22, 33, 44, 55, 66, 77, 88]
co = int(input())

```

```

# Hledané číslo se nachází v intervalu [l, p]
l = 0
p = len(kde) - 1

while l <= p:
    stred = (l+p) // 2
    if kde[stred] == co:    # Našli jsme
        print("Hodnota ", co, " nalezena na pozici", stred)
        break
    elif kde[stred] < co:
        l = stred + 1      # Jdeme doprava
    else:
        p = stred - 1      # Jdeme doleva
else:
    print("Hledaná hodnota nenalezena.")

```

Co kdybychom chtěli nalézt místo pro vložení nové hodnoty do seznamu?

To je podobná, i když mírně odlišná aplikace: nezajímá nás, zda hodnota existuje v seznamu, takže výsledek nemůže být neúspěšný: novou hodnotu můžeme vždycky vložit na správné místo. V aplikačním smyslu je toto fundamentálnější úloha.

```

# Vložení nové položky do setříděného seznamu

def insort(co: int, kam : list[int]) -> list[int]:
    """
    Zařadí hodnotu co na správné místo v setříděném seznamu kam
    """

    l = 0
    if co < kam[l]:
        return [co] + kam
    p = len(kam) - 1
    if co > kam[p]:
        return kam + [co]

    while p-l > 1:
        stred = (l + p) // 2
        strval = kam[stred]
        if strval > co:
            p = stred      # Jdeme doprava
        else:
            l = stred      # Jdeme doleva

    return kam[:p] + [co] + kam[p:]

kam = [11, 22, 33, 44, 55, 66, 77, 88]
co = int(input())

print(insort(co, kam))

```

Co kdybychom chtěli nalézt všechny stejné hodnoty, nejen jednu?

Všimněte si jemných rozdílů v algoritmech:

1. Hodnota v `p` striktně menší než hledaná:

```
while p-l > 1:
    stred = (l + p) // 2
    strval = kam[stred]
    if strval > co:
        p = stred      # Jdeme doprava
    else:
        l = stred      # Jdeme doleva
```

2. Hodnota v `l` striktně menší než hledaná:

```
while p-l > 1:
    stred = (l + p) // 2
    strval = kam[stred]
    if strval >= co:
        p = stred      # Jdeme doprava
    else:
        l = stred      # Jdeme doleva
```

První algoritmus vrací pozici na konci série stejných hodnot, druhý na jejím začátku.

Binární vyhledávání v Pythonu: modul `bisect`

```
import bisect

nums = [1,2,3,3,3,4,5,8]

print(bisect.bisect_left(nums, 3))
print(bisect.bisect_right(nums,3))
print(nums[bisect.bisect_left(nums, 3):bisect.bisect_right(nums,3)])
---
```

2
5
[3, 3, 3]

Alternativní řešení: využití algoritmu pro spojování setříděných seznamů

Umíme velmi efektivně spojovat setříděné seznamy (v jediném průchodu, tedy v čase $O(n)$).

k-tý největší prvek

Průběžné řešení:

```
from collections import deque
from bisect import insort

buffer = deque()
def update_buffer(val:int, limit = 1) -> None:
    global buffer
    insort(buffer, val)
    if len(buffer) > limit:
        buffer.popleft()
```

`insort` sice využívá binární vyhledávání, takže rychle najde, kam se má hodnota vložit, ale samotné vkládání je $O(n)$.

Můžeme výrazně ušetřit, pokud se nejdřív zeptáme, zda nová hodnota není menší než levá hodnota buffru.

Alternativně lze udržovat bufr utříděný pomocí probublávání: posouváme hodnotu, dokud nenajdeme v bufru nějakou menší, a tam ji vložíme. Maximum pak máme vlevo.

Řešení s načtením dat: rekurzivní dělení intervalu

Začneme malými úlohami:

1. Jak rychle vypočítat medián 5 čísel?
2. Mám 25 čísel. Rozdělím je na pětice a z mediánů pětic spočtu medián. Jak blízko bude k mediánu všech 25 čísel?
3. Jak efektivně přeorganizovat seznam tak, aby hodnoty menší než p byly nalevo od p a větší než p napravo?

Domácí úkoly

1. **Hledání v setříděném poli** - zadání jasné, ale váš kód musí být opravdu rychlý, tato úloha nic neodpustí.
2. **Přesmyčky** neboli anagramy: jak rychle zjistit, že jedno slovo je permutací písmen jiného slova? Opravdu rychle?1